BÁO CÁO TIẾN ĐỘ THỰC HIỆN ĐỀ TÀI GR2

Đề tài: Xây dựng trợ lý AI sử dụng kiến trúc AI Agent hỗ trợ khách hàng ngân hàng

AI Banking Assistant

- **Ngày báo cáo:** 24/10/2026 (Tuần từ 19/10/2026 đến 26/10/2026)
- **Giai đoạn:** Giai đoạn 1 — Hoàn thiện Kiến trúc RAG Đa tầng & Khởi động Tầng Bộ nhớ Agentic
- **Phiên bản:** 3.0

---

1. Kết quả đạt được trong tuần — Từ 19/10/2026 đến 26/10/2026

Trong tuần vừa qua, em đã hoàn thành việc nâng cấp toàn diện hệ thống từ bước phân đoạn tài liệu ban đầu thành một đường ống RAG chuyên sâu 7 Node hoàn chỉnh, đồng thời phát triển giao diện tương tác trực quan và thực hiện kiểm toán chất lượng thực nghiệm khắc nghiệt.

1.1. Hoàn thiện Hệ thống Đường ống Dữ liệu RAG 7 Node (Folder-to-Folder Pipeline)

Hệ thống được tổ chức thành 7 Node độc lập theo mô hình Folder-to-Folder, cho phép kiểm tra, lưu vết và đối soát dữ liệu đầu vào (Input) và đầu ra (Output) tại từng tầng:

- **Node 1 — Phân đoạn tài liệu (Chunking Node):** Chuẩn hóa dữ liệu theo Hợp đồng Ingestion Canonical DOCX. Giải quyết triệt để vấn đề mất dữ liệu của PDF bằng cách tập trung xử lý sâu trên định dạng Word: bảo toàn trọn vẹn định dạng in đậm, in nghiêng, gạch chân; tự động nối từ và sửa lỗi dính chữ sau dấu ngoặc; trích xuất hình ảnh qua OpenXML AST và lọc bỏ hình ảnh rác (chỉ giữ hình ảnh có chú thích - caption bên dưới).
- **Node 2 — Nhúng vector và lưu bộ đệm (Embedding Node):** Tích hợp mô hình multilingual-e5-large 1024 chiều qua FPT Cloud API kết hợp cơ chế lưu bộ đệm SQLite Cache (WAL mode đa luồng), giúp loại bỏ hoàn toàn chi phí và thời gian gọi lại API đối với các đoạn văn bản đã được nhúng.
- **Node 3 — Kho lưu trữ Vector và BM25 (Indexing Node):** Triển khai song song hai cơ chế tìm kiếm trong Qdrant Localhost (Dense Vector 1024-dim với đồ thị HNSW) và Okapi BM25 Sparse Index, kèm cơ chế tự động chuyển sang chế độ In-Memory khi xảy ra xung đột khóa tệp trên ổ đĩa.
- **Node 4 — Chuẩn hóa câu hỏi (Query Parser Node):** Tự động chuẩn hóa từ viết tắt ngân hàng (eKYC, TKTT, Smart OTP, Digibank), làm sạch ký tự rác, và trích xuất chuẩn xác các tham chiếu điều khoản pháp lý (Điều X, Khoản Y).
- **Node 5 — Tìm kiếm lai kết hợp (Hybrid Retrieval Node):** Thực thi truy vấn đồng thời trên cả Dense Vector và BM25, sau đó hợp nhất kết quả bằng thuật toán Reciprocal Rank Fusion (RRF k=60), dung hòa ưu thế hiểu ngữ nghĩa của Vector với khả năng bắt chính xác số hiệu văn bản của BM25.
- **Node 6 — Tái xếp hạng ngữ nghĩa (Cross-Encoder Reranker Node):** Sử dụng mô hình bge-reranker-v2-m3 để chấm điểm chéo cặp câu hỏi - đoạn trích, kéo các đoạn văn bản trả lời đúng nhất lên Top 3.
- **Node 7 — Sinh câu trả lời & Phòng vệ an toàn (Generator & Guardrails Node):** Ứng dụng mô hình DeepSeek-V4-Flash định tuyến Cloud, đóng gói ngữ cảnh Markdown kèm thẻ trích dẫn nguồn pháp lý. Tích hợp sẵn Banking Guardrails: phát hiện đòn tấn công Prompt Injection (kể cả dạng mã hóa Leetspeak), che giấu thông tin cá nhân PII (CCCD, tài khoản, 16 số thẻ tín dụng), và cảnh báo lừa đảo chiếm đoạt OTP/mật khẩu.

1.2. Xây dựng Máy chủ Web API và Giao diện Trực quan hóa Liên hoàn

- **Máy chủ API chuyên dụng:** Triển khai máy chủ FastAPI (main.py) cung cấp đầy đủ các cổng giao tiếp API (/api/chat, /api/config, /api/nodes, /api/pipeline/run-folders), phục vụ trực tiếp giao diện Web tại địa chỉ http://127.0.0.1:8000.
- **Giao diện Khách hàng:** Giao diện Web tương tác (HTML/CSS/JS thuần không phụ thuộc thư viện nặng) tích hợp khung trò chuyện thời gian thực, hiển thị trích dẫn nguồn điều khoản, thẻ phân loại ý định và thời gian phản hồi.
- **Bảng điều khiển Node Explorer:** Cho phép duyệt cây thư mục dữ liệu của cả 7 Node, xem trước nội dung tệp JSON đầu vào/đầu ra, giúp quá trình đối soát và nghiệm thu đề tài minh bạch 100%.

1.3. Kiểm toán Chất lượng Thực nghiệm & Khắc phục Lỗ hổng (Chaos Engineering)

Thay vì dựa vào các bài kiểm thử giả định đơn giản báo '100% Pass' nhưng thực tế tiềm ẩn nhiều lỗi, em đã xây dựng bộ kiểm định chất lượng độc lập 5 cấp độ gồm 43 kịch bản cực hạn (Chaos Engineering):

Chỉ số Kiểm định (Metric)	Kết quả Ban đầu	Kết quả Thực nghiệm	Đánh giá Kỹ thuật
Độ bao phủ dữ liệu PDF	100% (Pass ảo)	38.5% (Mất 61.5% trang)	Phát hiện trần cắt 5 trang -> Chuẩn hóa qua DOCX
Nguyên vẹn ranh giới câu	100% (Pass ảo)	61.07% (Cắt cụt 38.9%)	Nâng cấp bộ ngắt câu ngữ nghĩa wtpsplit
Hit Rate@1 (Top 1 đúng nguồn)	Chưa đo lường	83.33% (15/18 truy vấn)	RRF và Dense định vị chính xác tài liệu
Hit Rate@3 (Top 3 đúng nguồn)	Chưa đo lường	88.89% (16/18 truy vấn)	Cung cấp đủ ngữ cảnh cho LLM tổng hợp
Hit Rate@5 (Top 5 đúng nguồn)	Chưa đo lường	94.44% (17/18 truy vấn)	Tỷ lệ bao phủ tri thức xuất sắc
Mean Reciprocal Rank (MRR)	Chưa đo lường	0.8722	Điểm số xếp hạng tương đối cao
Kháng bẫy Hallucination	Chưa đo lường	100.0% (2/2 bẫy bị chặn)	LLM từ chối gói vay bịa đặt 0% và lãi suất 18%
Phòng vệ Guardrails (OTP/PII)	Chưa đo lường	100.0% (Vá xong 2 lỗ hổng)	Chặn Prompt Injection Leetspeak & che số thẻ

Đặc biệt, quá trình kiểm toán đã bóc tách và sửa chữa thành công 3 lỗi nghiêm trọng trong mã nguồn: (1) Lỗi crash AttributeError khi chunk chứa nội dung rỗng trong Embedder; (2) Lỗ hổng để lọt số thẻ tín dụng phân cách bằng dấu cách (4532 0156 7890 1234) trong Guardrail; và (3) Lỗ hổng vượt rào bằng ký tự Leetspeak (1gnore...). Toàn bộ 43 ca kiểm thử hiện nay đều đã vượt qua 100%.

2. Kế hoạch thực hiện tuần tới — Từ 26/10/2026 đến 02/11/2026

Sau khi hoàn thiện vững chắc nền tảng RAG đa tầng, trọng tâm nghiên cứu và triển khai trong tuần tiếp theo là nâng cấp hệ thống từ mô hình hỏi đáp đơn lượt (Stateless RAG) sang Kiến trúc Trợ lý AI có Trạng thái (Stateful AI Agent), bắt đầu triển khai toàn diện Phân hệ Lưu trữ Bộ nhớ (Memory Storage) cho bot:

- **Xây dựng Kiến trúc Bộ nhớ Đa tầng (Multi-Tier Memory Architecture):** Thiết lập cơ chế bộ nhớ 3 cấp: (1) Bộ nhớ làm việc ngắn hạn (Working/Short-term Memory) lưu trữ ngữ cảnh hội thoại trượt (Sliding Window Buffer) giúp bot duy trì mạch đàm thoại liên tục; (2) Bộ nhớ dài hạn (Long-term Episodic & Semantic Memory) lưu trữ thông tin sở thích, lịch sử giao dịch và hồ sơ định danh của khách hàng trên cơ sở dữ liệu SQLite/Redis; (3) Bộ nhớ tóm tắt tự động (Hierarchical Conversation Summarization) định kỳ nén các phiên đàm thoại dài bằng LLM để giữ trọn vẹn ngữ cảnh mà không làm tràn cửa sổ ngữ cảnh.
- **Phát triển Phân hệ Viết lại Truy vấn theo Ngữ cảnh (Contextual Query Rewriter):** Xây dựng Node xử lý ngôn ngữ trung gian đứng trước tầng Retrieval, có nhiệm vụ phân tích lịch sử hội thoại từ bộ nhớ để tự động bổ sung chủ ngữ, đại từ khuyết thiếu trong câu hỏi của khách hàng (ví dụ: khi khách hàng hỏi 'Phí của nó là bao nhiêu?', hệ thống tự động suy luận 'nó' là 'Thẻ Vietcombank Visa Signature' đã đề cập ở câu trước để tìm kiếm chính xác).
- **Tích hợp Trình quản lý Phiên (Session Manager & Checkpointer):** Ứng dụng LangGraph Checkpointer hoặc thiết kế Session Store chuyên biệt, cho phép lưu trữ vết trạng thái đa phiên, hỗ trợ khách hàng tiếp tục cuộc trò chuyện sau khi tải lại trang web hoặc chuyển đổi thiết bị.
- **Nâng cấp Giao diện Web hỗ trợ Quản lý Phiên hội thoại:** Bổ sung thanh điều hướng danh sách các phiên trò chuyện (Chat History Sidebar) ở giao diện Frontend, cho phép tạo phiên hội thoại mới, đổi tên phiên và xem lại lịch sử tư vấn tài chính theo thời gian thực.